Wytyczne adnotacji

Kontekst:

Tworzymy lepsze metody testowania modeli do automatycznego wykrywania mowy nienawiści online. W tym celu zebraliśmy zestaw danych zawierający kilka tysięcy krótkich wypowiedzi tekstowych. Każda wypowiedź odzwierciedla szczególny aspekt mowy nienawiści w internecie.

Twoje zadanie:

- 1. Zaznacz czy każda przydzielona Ci wypowiedź jest nienawistna lub nie nienawistna.
- 2. Zaznacz wszystkie wypowiedzi, które są nierealistyczne.

Co mamy na myśli przez "nienawistne"?

Definiujemy **mowę nienawiści** jako obelgi kierowane w stosunku do chronionych grup lub ich członków za przynależność do nich. Chronione grupy są oparte o wiek, niepełnosprawność, rasę (kolor skory, obywatelstwo, pochodzenie etniczne lub narodowe), religię lub wierzenia, płeć i orientację seksualną, a także tożsamość płciową.

Co mamy na myśli przez "nierealistyczne"?

Celowo zostawiliśmy tę decyzję Tobie. Nie skonstruowaliśmy żadnych wypowiedzi by były nierealistyczne, więc to oznaczenie jest zaledwie narzędziem zapewniającym dobrą jakość danych.

Kilka uwag przydatnych podczas adnotacji:

- Język, który jest nienawistny, może w pewnych kontekstach być użyty nie nienawistnie (np., sprzeciw mowie nienawiści wykorzystujący wyzwiska: "To nie jest w porządku nazywać ludzi czarnuchami.")
- Cel obelgi ma znaczenie w decydowaniu czy coś jest mową nienawiści. Ataki interpersonalne i przeciw nie-chronionym grupom, takim jak profesje czy afiliacje, nie są mową nienawiści. (np. "Nienawidzę Żydów." jest nienawistne, ale "Nienawidzę cię.", "Nienawidzę tego stołu." i "Nienawidzę lekarzy." już nie).

Inne przydatne wskazówki:

- Nie oznaczaj wypowiedzi jako nierealistyczne tylko dlatego, że mają małe szanse wystąpić w internecie. Oznaczaj w ten sposób tylko wypowiedzi, które są bezsensowne lub gramatycznie nieprawidłowe.
- Prosimy o wykonanie adnotacji samodzielnie i bez omawiania ich z innymi.
- 3. Większość wypowiedzi jest bardzo krótka, więc prosimy nie myśleć o nich zbyt dużo.

Dziękujemy za Twoją pracę nad tym projektem!